

Profesor: Duván Cataño

Estudiante: Diego Alexander Reyes Torralba

Cuestionario

1. Reconocimiento inicial del conjunto de datos credit_dataset.csv:

Identifique:

- Numero de observaciones:

```
In [62]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import scipy
from scipy import stats
from pathlib import Path

raiz_proyecto = Path.cwd().parent
ruta_archivo = raiz_proyecto / "data" / "raw" / "credit_dataset.csv"
df = pd.read_csv(ruta_archivo)
print(f"Numero de observaciones: {df.shape[0]}")
```

Numero de observaciones: 9709

- Numero de variables:

```
In [63]: print(f"Numero de variables: {df.shape[1]}")
```

Numero de variables: 20

- Tipo de cada variable (numérica, categórica, etc.):

```
In [64]: print(df.info())
display(df.head())
```

```
<class 'pandas.DataFrame'>
RangeIndex: 9709 entries, 0 to 9708
Data columns (total 20 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID                    9709 non-null   int64
1   Gender                9709 non-null   int64
2   Own_car               9709 non-null   int64
3   Own_property          9709 non-null   int64
4   Work_phone            9709 non-null   int64
5   Phone                 9709 non-null   int64
6   Email                 9709 non-null   int64
7   Unemployed            9709 non-null   int64
8   Num_children          9709 non-null   int64
9   Num_family            9709 non-null   int64
10  Account_length        9709 non-null   int64
11  Total_income          9709 non-null   float64
12  Age                   9709 non-null   float64
13  Years_employed        9709 non-null   float64
14  Income_type           9709 non-null   str
15  Education_type        9709 non-null   str
16  Family_status         9709 non-null   str
17  Housing_type          9709 non-null   str
18  Occupation_type       9709 non-null   str
19  Target                9709 non-null   int64
dtypes: float64(3), int64(12), str(5)
memory usage: 1.5 MB
None
```

	ID	Gender	Own_car	Own_property	Work_phone	Phone	Email	Unemployed	Nu
0	5008804	1	1	1	1	0	0	0	
1	5008806	1	1	1	0	0	0	0	
2	5008808	0	0	1	0	1	1	0	
3	5008812	0	0	1	0	0	0	1	
4	5008815	1	1	1	1	1	1	0	



#	Column	Tipo de Variable	Subtipo
0	ID	Categórica	Nominal
1	Gender	Categórica	Dicotómica (Booleana)
2	Own_car	Categórica	Dicotómica (Booleana)

#	Column	Tipo de Variable	Subtipo
3	Own_property	Categórica	Dicotómica (Booleana)
4	Work_phone	Categórica	Dicotómica (Booleana)
5	Phone	Categórica	Dicotómica (Booleana)
6	Email	Categórica	Dicotómica (Booleana)
7	Unemployed	Categórica	Dicotómica (Booleana)
8	Num_children	Cuantitativa	Discreta
9	Num_family	Cuantitativa	Discreta
10	Account_length	Cuantitativa	Discreta
11	Total_income	Cuantitativa	Continua
12	Age	Cuantitativa	Continua
13	Years_employed	Cuantitativa	Continua
14	Income_type	Categórica	Nominal
15	Education_type	Categórica	Nominal
16	Family_status	Categórica	Nominal
17	Housing_type	Categórica	Nominal
18	Occupation_type	Categórica	Nominal
19	Target	Categórica	Dicotómica (Booleana)

- Posibles valores faltantes o inconsistencias

```
In [65]: ## Valores faltantes en todas las columnas
display(df.isna().sum())

## Tipos de datos
display(df.dtypes)

## ID únicos
display(df['ID'].is_unique)
```

```

ID          0
Gender      0
Own_car     0
Own_property 0
Work_phone  0
Phone       0
Email       0
Unemployed  0
Num_children 0
Num_family  0
Account_length 0
Total_income 0
Age         0
Years_employed 0
Income_type 0
Education_type 0
Family_status 0
Housing_type 0
Occupation_type 0
Target      0
dtype: int64
ID          int64
Gender      int64
Own_car     int64
Own_property int64
Work_phone  int64
Phone       int64
Email       int64
Unemployed  int64
Num_children int64
Num_family  int64
Account_length int64
Total_income float64
Age         float64
Years_employed float64
Income_type str
Education_type str
Family_status str
Housing_type str
Occupation_type str
Target      int64
dtype: object
True

```

Observamos que el ID no posee datos duplicados por lo que cada ID es único, tampoco hay valores faltantes en ninguna de las columnas. Sin embargo, observamos que los tipos de datos de las columnas dicotómicas están definidos como enteros en vez de valores booleanos.

```

In [66]: ## Seleccionar Las columnas
        cols = ['Own_car', 'Own_property', 'Work_phone', 'Phone', 'Email', 'Unemployed', 'T

## Cambiar el tipo de dato para Las columnas
        df[cols] = df[cols].astype(bool)

```

```
## Mostrar los nuevos tipos de datos
print(df.dtypes)
```

```
ID                int64
Gender            int64
Own_car           bool
Own_property      bool
Work_phone        bool
Phone             bool
Email             bool
Unemployed        bool
Num_children      int64
Num_family        int64
Account_length    int64
Total_income      float64
Age              float64
Years_employed    float64
Income_type       str
Education_type    str
Family_status     str
Housing_type      str
Occupation_type   str
Target           bool
dtype: object
```

2. Análisis univariado de variables cualitativas.

Seleccione al menos tres variables categóricas y construya:

- Tabla de frecuencias absolutas, relativas, acumuladas y porcentuales:

```
In [67]: cols = ['Income_type', 'Education_type', 'Family_status']

for n in cols:
    print(f"\n--- Tabla de frecuencias: {n} ---")
    tab = df[n].value_counts().to_frame(name='Cant.')
    tab['%'] = (df[n].value_counts(normalize=True) * 100).round(2)
    tab['Cant. Acum.'] = tab['Cant.'].cumsum()
    tab['% Acum.'] = tab['%'].cumsum().round(2)

    print(tab)
```

--- Tabla de frecuencias: Income_type ---

	Cant.	%	Cant. Acum.	% Acum.
Income_type				
Working	4960	51.09	4960	51.09
Commercial associate	2312	23.81	7272	74.90
Pensioner	1712	17.63	8984	92.53
State servant	722	7.44	9706	99.97
Student	3	0.03	9709	100.00

--- Tabla de frecuencias: Education_type ---

	Cant.	%	Cant. Acum.	% Acum.
Education_type				
Secondary / secondary special	6761	69.64	6761	69.64
Higher education	2457	25.31	9218	94.95
Incomplete higher	371	3.82	9589	98.77
Lower secondary	114	1.17	9703	99.94
Academic degree	6	0.06	9709	100.00

--- Tabla de frecuencias: Family_status ---

	Cant.	%	Cant. Acum.	% Acum.
Family_status				
Married	6530	67.26	6530	67.26
Single / not married	1359	14.00	7889	81.26
Civil marriage	836	8.61	8725	89.87
Separated	574	5.91	9299	95.78
Widow	410	4.22	9709	100.00

En este análisis de variables categoricas podemos observar que predomina la fuerza laboral, los nivbeles educativos medios (educación secundaria) y el estado civil de las personas casadas.

1. **Income_type** : Teniendo en cuenta que las categorais working, comercial associate y state servant pueden clasificarse bajo una sola, podemos decir que el 82.34% de las personas reciben ingresos de un trabajo. Mientras que 17.63 son pensionados y el 0.03% restante estudia.
2. **Education_type** : El nivel educativo se concentra en la educacion media, solo 1 de 4 personas aproximadamente tiene educación superior, y el 0.06% restante tiene educación académica.
3. **Family_status** : El estado civil casdo es el más comun con un 67.26% de los casos.

El perfil dominante en este dataset es de un individuo trabajador en el sector privado, con educacion secundaria terminada y casado.

3. Visualización de variables categóricas.

```
In [68]: sns.set_theme(style="whitegrid")

fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(22, 7))
```

```


sns.countplot(data=df, y='Income_type', ax=ax[0], color='skyblue', edgecolor='black')
ax[0].set_xlabel('Frequency')
ax[0].set_ylabel('Income Type')

sns.countplot(data=df, y='Education_type', ax=ax[1], color='salmon', edgecolor='black')
ax[1].set_title('Distribution of Education Type', fontweight='bold')
ax[1].set_xlabel('Frequency')
ax[1].set_ylabel('Education Type')

sns.countplot(data=df, y='Family_status', ax=ax[2], color='lightgreen', edgecolor='black')
ax[2].set_title('Distribution of Family Status', fontweight='bold')
ax[2].set_xlabel('Frequency')
ax[2].set_ylabel('Family Status')

plt.tight_layout()
plt.show()

```



```

In [69]: fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(22, 7))

income_counts = df['Income_type'].value_counts()
education_counts = df['Education_type'].value_counts()
family_counts = df['Family_status'].value_counts()


ax[0].pie(income_counts.values, labels=income_counts.index, autopct='%1.2f%%')
ax[0].set_title('Distribution of Income Type', fontweight='bold')

ax[1].pie(education_counts.values, labels=education_counts.index, autopct='%1.2f%%')
ax[1].set_title('Distribution of Education Type', fontweight='bold')

ax[2].pie(family_counts.values, labels=family_counts.index, autopct='%1.2f%%')
ax[2].set_title('Distribution of Family Status', fontweight='bold')

plt.tight_layout()
plt.show()

```



Si bien el gráfico de pastel es visualmente atractivo para resaltar una parte proporcional de un todo y es fácil de entender, creo que no es la mejor opción para representar como se distribuyen estas variables, si lo comparamos con el gráfico de barras, en este se observan diferencias más claras entre las categorías.

4. Tablas de frecuencias para variables numéricas.

Selecciona dos variables cuantitativas y:

- Determine el número de clases usando la regla de Sturges:

```
In [70]: n = len(df['Total_income'])
k = int(np.ceil(1 + 3.322 * np.log10(n)))
print(f"Número de clases: {k}")
```

Número de clases: 15

- Tabla de frecuencias absolutas, relativas y acumuladas:

```
In [71]: cols = ['Total_income', 'Years_employed']

for n in cols:

    print(f"\n--- Tabla de frecuencias: {n} ---")
    k = int(np.ceil(1 + 3.322 * np.log10(len(df[n]))))
    intervalos = pd.cut(df[n], bins=k)
    tab = intervalos.value_counts().sort_index().to_frame(name='Cant.')
    tab['%'] = (intervalos.value_counts(normalize=True).sort_index() * 100).round(2)
    tab['Cant. Acum.'] = tab['Cant.'].cumsum()
    tab['% Acum.'] = tab['%'].cumsum().round(2)
    tab['Marca de Clase (Xi)'] = [i.mid for i in tab.index]

    display(tab)
```

--- Tabla de frecuencias: Total_income ---

	Cant.	%	Cant. Acum.	% Acum.	Marca de Clase (Xi)
Total_income					
(25452.0, 130200.0]	2901	29.88	2901	29.88	77826.0
(130200.0, 233400.0]	4928	50.76	7829	80.64	181800.0
(233400.0, 336600.0]	1229	12.66	9058	93.30	285000.0
(336600.0, 439800.0]	421	4.34	9479	97.64	388200.0
(439800.0, 543000.0]	152	1.57	9631	99.21	491400.0
(543000.0, 646200.0]	18	0.19	9649	99.40	594600.0
(646200.0, 749400.0]	34	0.35	9683	99.75	697800.0
(749400.0, 852600.0]	9	0.09	9692	99.84	801000.0
(852600.0, 955800.0]	11	0.11	9703	99.95	904200.0
(955800.0, 1059000.0]	1	0.01	9704	99.96	1007400.0
(1059000.0, 1162200.0]	3	0.03	9707	99.99	1110600.0
(1162200.0, 1265400.0]	0	0.00	9707	99.99	1213800.0
(1265400.0, 1368600.0]	1	0.01	9708	100.00	1317000.0
(1368600.0, 1471800.0]	0	0.00	9708	100.00	1420200.0
(1471800.0, 1575000.0]	1	0.01	9709	100.01	1523400.0

--- Tabla de frecuencias: Years_employed ---

	Cant.	%	Cant. Acum.	% Acum.	Marca de Clase (Xi)
Years_employed					
(-0.043, 2.868]	4139	42.63	4139	42.63	1.4125
(2.868, 5.736]	2027	20.88	6166	63.51	4.3020
(5.736, 8.604]	1290	13.29	7456	76.80	7.1700
(8.604, 11.472]	845	8.70	8301	85.50	10.0380
(11.472, 14.34]	469	4.83	8770	90.33	12.9060
(14.34, 17.208]	342	3.52	9112	93.85	15.7740
(17.208, 20.076]	190	1.96	9302	95.81	18.6420
(20.076, 22.944]	144	1.48	9446	97.29	21.5100
(22.944, 25.812]	101	1.04	9547	98.33	24.3780
(25.812, 28.68]	61	0.63	9608	98.96	27.2460
(28.68, 31.549]	40	0.41	9648	99.37	30.1145
(31.549, 34.417]	30	0.31	9678	99.68	32.9830
(34.417, 37.285]	14	0.14	9692	99.82	35.8510
(37.285, 40.153]	9	0.09	9701	99.91	38.7190
(40.153, 43.021]	8	0.08	9709	99.99	41.5870

1. **Total_income** : El número de clases según la regla de Sturges es de 15. La distribución del ingreso total se concentra en los dos primeros intervalos ya que el 80.64 % de las personas ganan entre 25,452 y 233,400. La distribución es sesgada a la izquierda (asimetría positiva), indicando que la mayoría de las personas tienen ingresos bajos, mientras que un pequeño porcentaje tiene ingresos muy altos. Hay un valor atípico en el intervalo de 955,800 a 1,059,000 que representa el 0.01% de los casos.
2. **Years_employed** : El número de clases según la regla de Sturges es de 15. En este caso el 42.63% de las personas tienen menos de 2.8 años en su empleo actual. Si sumamos el segundo intervalo, descubrimos que el 63.51% de las personas tienen menos de 5.7 años en su empleo actual. Hay un deceso progresivo a medida que aumentan los intervalos de años trabajados.

En general para estas dos variables podemos decir que la mayoría de las personas tienen ingresos bajos y poca experiencia laboral.

5. Medidas de tendencia central:

Para al menos tres variables cuantitativas:

- Calcule la media, mediana y moda:

```
In [72]: cols = ['Total_income', 'Years_employed', 'Age']

summary = {
    'Media': df[cols].mean(),
    'Mediana': df[cols].median(),
    'Moda': df[cols].mode().iloc[0],
}

central_table = pd.DataFrame(summary).round(2)
display(central_table)
```

	Media	Mediana	Moda
Total_income	181228.19	157500.00	135000.00
Years_employed	5.66	3.76	0.00
Age	43.78	42.74	28.54

Los datos presentan un sesgo positivo, especialmente en los ingresos y la antigüedad laboral, donde la media se ve inflada por valores altos como el outlier que mencionamos en el anterior análisis. La mediana es una medida más robusta para describir a la población típica (\$157,500 en ingresos y 3.7 años de empleo). La edad muestra una distribución más equilibrada y madura en torno a los 42-43 años.

6. Medidas de dispersión y variabilidad:

Para las mismas variables del punto anterior, calcule:

- Rango, varianza, desviación estándar, coeficiente de variación, rango intercuartílico:

```
In [73]: cols = ['Total_income', 'Years_employed', 'Age']

summary = {
    'Rango': df[cols].max() - df[cols].min(),
    'Varianza': df[cols].var(),
    'Desviación estándar': df[cols].std(),
    'Coeficiente de variación': df[cols].std() / df[cols].mean() * 100,
    'Rango intercuartílico': df[cols].quantile(0.75) - df[cols].quantile(0.25),
}

deviation_table = pd.DataFrame(summary).round(2)
display(deviation_table)
```

	Rango	Varianza	Desviación estándar	Coefficiente de variación	Rango intercuartílico
Total_income	1548000.00	9.855983e+09	99277.31	54.78	112500.00
Years_employed	43.02	4.022000e+01	6.34	111.96	7.27
Age	48.36	1.351600e+02	11.63	26.55	19.51

Los datos son muy heterogéneos, especialmente en la antigüedad laboral, donde la variabilidad es del 111%. Los ingresos (Total_income) también presentan una dispersión alta de 54.78% gracias al rango amplio de salarios, mientras que la Edad se mantiene como la métrica más estable (26.55%).

7. Medidas de posicion:

Para al menos dos variables numéricas, calcule:

- Cuartiles, deciles y percentiles:

```
In [74]: cols = ['Total_income', 'Years_employed']

summary = {
    'Cuartiles': df[cols].quantile([0.25, 0.5, 0.75]),
    'Deciles': df[cols].quantile([0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]),
    'Percentiles': df[cols].quantile([0.01, 0.05, 0.1, 0.25, 0.5, 0.75, 0.9, 0.95,
    ])

position_table = pd.concat(summary, axis=0)
position_table.index.names = ['Medida', 'Cuantil']
position_table = position_table.reset_index()

display(position_table)
display(position_table)
```

	Medida	Cuantil	Total_income	Years_employed
0	Cuartiles	0.25	112500.0	0.928150
1	Cuartiles	0.50	157500.0	3.761884
2	Cuartiles	0.75	225000.0	8.200031
3	Deciles	0.10	90000.0	0.000000
4	Deciles	0.20	112500.0	0.456135
5	Deciles	0.30	130500.0	1.431925
6	Deciles	0.40	135000.0	2.568157
7	Deciles	0.50	157500.0	3.761884
8	Deciles	0.60	180000.0	5.117148
9	Deciles	0.70	202500.0	6.962498
10	Deciles	0.80	225000.0	9.472611
11	Deciles	0.90	292500.0	14.095840
12	Percentiles	0.01	49500.0	0.000000
13	Percentiles	0.05	67500.0	0.000000
14	Percentiles	0.10	90000.0	0.000000
15	Percentiles	0.25	112500.0	0.928150
16	Percentiles	0.50	157500.0	3.761884
17	Percentiles	0.75	225000.0	8.200031
18	Percentiles	0.90	292500.0	14.095840
19	Percentiles	0.95	360000.0	18.792994
20	Percentiles	0.99	540000.0	29.089824

	Medida	Cuantil	Total_income	Years_employed
0	Cuartiles	0.25	112500.0	0.928150
1	Cuartiles	0.50	157500.0	3.761884
2	Cuartiles	0.75	225000.0	8.200031
3	Deciles	0.10	90000.0	0.000000
4	Deciles	0.20	112500.0	0.456135
5	Deciles	0.30	130500.0	1.431925
6	Deciles	0.40	135000.0	2.568157
7	Deciles	0.50	157500.0	3.761884
8	Deciles	0.60	180000.0	5.117148
9	Deciles	0.70	202500.0	6.962498
10	Deciles	0.80	225000.0	9.472611
11	Deciles	0.90	292500.0	14.095840
12	Percentiles	0.01	49500.0	0.000000
13	Percentiles	0.05	67500.0	0.000000
14	Percentiles	0.10	90000.0	0.000000
15	Percentiles	0.25	112500.0	0.928150
16	Percentiles	0.50	157500.0	3.761884
17	Percentiles	0.75	225000.0	8.200031
18	Percentiles	0.90	292500.0	14.095840
19	Percentiles	0.95	360000.0	18.792994
20	Percentiles	0.99	540000.0	29.089824

P25: El 25% de los empleados gana hasta

112,500 y tienen menos de 1 año en la empresa. * * P_{50} (mediana) : * * El ingreso típico es de 157,500 y la mitad de los empleados lleva menos de 3.76 años.. **P90:** Solo el 10% supera ingresos de \$292,500 y tiene más de 14 años de antigüedad.

8. Análisis grafico de distribución:

Construya para almenos tres variables cuantitativas:

- Histogramas:

```
In [75]: sns.set_theme(style="whitegrid")


fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(22, 7))

sns.histplot(data=df, x='Total_income', bins='sturges', kde=True, color='skyblue',
ax[0].set_title('Distribution of Total Income', fontweight='bold')
ax[0].set_xlabel('Total Income')
ax[0].set_ylabel('Frequency')

sns.histplot(data=df, x='Years_employed', bins='sturges', kde=True, color='salmon',
ax[1].set_title('Distribution of Years Employed', fontweight='bold')
ax[1].set_xlabel('Years Employed')
ax[1].set_ylabel('Frequency')

sns.histplot(data=df, x='Age', bins='sturges', kde=True, color='lightgreen', edgeco
ax[2].set_title('Distribution of Age', fontweight='bold')
ax[2].set_xlabel('Age')
ax[2].set_ylabel('Frequency')

plt.tight_layout()
plt.show()
```




- Diagrama de cajas:

```
In [76]: sns.set_theme(style="whitegrid")

fig, axes = plt.subplots(nrows=2, ncols=2, figsize=(25, 12))

sns.boxplot(data=df, x='Total_income', color='skyblue', ax=axes[0, 0])
sns.boxplot(data=df, x='Years_employed', color='salmon', ax=axes[0, 1])
sns.boxplot(data=df, x='Age', color='lightgreen', ax=axes[1, 0])
sns.boxplot(data=df, x='Total_income', y='Education_type', color='skyblue', ax=axes

plt.tight_layout()
plt.show()
```



- Polígono de frecuencias:

```
In [77]: sns.set_theme(style="whitegrid")


fig, ax = plt.subplots(nrows=1, ncols=3, figsize=(22, 7))

sns.histplot(data=df, x='Total_income', element='poly', color='skyblue', edgecolor='black')
ax[0].set_title('Distribution of Total Income', fontweight='bold')
ax[0].set_xlabel('Total Income')
ax[0].set_ylabel('Frequency')

sns.histplot(data=df, x='Years_employed', element='poly', color='salmon', edgecolor='black')
ax[1].set_title('Distribution of Years Employed', fontweight='bold')
ax[1].set_xlabel('Years Employed')
ax[1].set_ylabel('Frequency')

sns.histplot(data=df, x='Age', element='poly', color='lightgreen', edgecolor='black')
ax[2].set_title('Distribution of Age', fontweight='bold')
ax[2].set_xlabel('Age')
ax[2].set_ylabel('Frequency')

plt.tight_layout()
plt.show()
```



Las variables Ingreso Total y Años de Empleo muestran una fuerte asimetría positiva, con la mayoría de los datos concentrados en valores bajos y una pequeña proporción de observaciones altas que generan numerosos valores atípicos. En ambos casos el rango total es amplio y la mayor parte de la población se agrupa en intervalos reducidos.

La variable Edad presenta una distribución mucho más equilibrada y cercana a la simetría, sin evidencia de valores atípicos. Los datos se distribuyen de forma relativamente uniforme entre los diferentes rangos de edad.

9. Medidas de forma y curtosis:

Para al menos dos variables numéricas, calcule:

- Coeficiente de asimetría (skewness):

```
In [78]: cols = ['Total_income', 'Years_employed', 'Age']

for i in cols:
    skewness = scipy.stats.skew(df[[i]], axis=0, bias=True)
    print(f"Coeficiente de asimetría para {i}: {skewness}")

for i in cols:
    kurtosis = scipy.stats.kurtosis(df[[i]], axis=0, bias=True)
    print(f"Curtosis para {i}: {kurtosis}")
```

```
Coeficiente de asimetría para Total_income: [2.65895169]
Coeficiente de asimetría para Years_employed: [1.84468002]
Coeficiente de asimetría para Age: [0.15038316]
Curtosis para Total_income: [15.77204296]
Curtosis para Years_employed: [4.22002614]
Curtosis para Age: [-1.05335985]
```

1. **Total_Income** : Teniendo en cuenta el coeficiente de asimetría se puede decir que la distribución es asimétrica hacia la derecha (asimetría positiva) ya que su valor es de 2.65. Indicando que la mayoría de ingresos se concentran en los valores más bajos, para el caso de la kurtosis, el valor es de 15.77, lo que indica una distribución leptocúrtica, con colas más pesadas y un pico más alto que una distribución normal.
2. **Years_employed** : El coeficiente de asimetría de 1.84 también indica una distribución asimétrica hacia la derecha, aunque menos pronunciada que en el caso de los ingresos. La kurtosis de 4.22 sugiere una distribución leptocúrtica, con colas más pesadas y un pico más alto que una distribución normal, aunque menos extrema que en el caso de los ingresos.
3. **Age** : El coeficiente de asimetría de 0.15 indica una distribución casi simétrica, cercana a la distribución normal ya que se acerca a 0, y la kurtosis de -1.05 indica una distribución platicúrtica, con colas más ligeras y un pico más bajo que una distribución normal.

10. Detección y análisis de valores atípicos:

Utilizando diagramas de caja y criterios estadísticos:


- Identifique posibles valores atípicos
- Explique como afectan las medidas de tendencia central y dispersión
- Compare resultados antes y despues de eliminar outliers

```
In [79]: sns.set_theme(style="whitegrid")

fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(25, 12))

sns.boxplot(data=df, x='Total_income', color='skyblue', ax=axes[0])
sns.boxplot(data=df, x='Years_employed', color='salmon', ax=axes[1])
sns.boxplot(data=df, x='Age', color='lightgreen', ax=axes[2])

plt.tight_layout()
plt.show()
```



Usando los diagramas de cajas para las variables `Total_income` y `Years_employed`, se identifican varios valores atípicos que se encuentran por encima del rango intercuartílico. Estos outliers representan casos extremos de ingresos muy altos a partir de aproximadamente 400.000 dólares y casos de tiempo de empleo muy amplios a partir de aproximadamente 20. Para la variable `Age`, no se identifican valores atípicos, ya que los datos se distribuyen de forma relativamente uniforme entre los diferentes rangos de edad.

```
In [80]: iqr_income = stats.iqr(df['Total_income'])
print(f"Rango intercuartílico para Total_income: {iqr_income}")
q1_income = df['Total_income'].quantile(0.25)
q3_income = df['Total_income'].quantile(0.75)
income_upper_bound = q3_income + 1.5 * iqr_income
income_lower_bound = q1_income - 1.5 * iqr_income

iqr_years = stats.iqr(df['Years_employed'])
```

```

print(f"Rango intercuartílico para Years_employed: {iqr_years}")
q1_years = df['Years_employed'].quantile(0.25)
q3_years = df['Years_employed'].quantile(0.75)
years_upper_bound = q3_years + 1.5 * iqr_years
years_lower_bound = q1_years - 1.5 * iqr_years

iqr_age = stats.iqr(df['Age'])
print(f"Rango intercuartílico para Age: {iqr_age}")
q1_age = df['Age'].quantile(0.25)
q3_age = df['Age'].quantile(0.75)
age_upper_bound = q3_age + 1.5 * iqr_age
age_lower_bound = q1_age - 1.5 * iqr_age

df_clean = df[
    (df['Total_income'] >= income_lower_bound) & (df['Total_income'] <= income_upper_bound) &
    (df['Years_employed'] >= years_lower_bound) & (df['Years_employed'] <= years_upper_bound) &
    (df['Age'] >= age_lower_bound) & (df['Age'] <= age_upper_bound)
]

print(f"\nObservaciones originales: {len(df)}")
print(f"Observaciones después de eliminar outliers: {len(df_clean)}")
print(f"Outliers eliminados: {len(df) - len(df_clean)}")

```

Rango intercuartílico para Total_income: 112500.0

Rango intercuartílico para Years_employed: 7.271881010561477

Rango intercuartílico para Age: 19.507587424793115

Observaciones originales: 9709

Observaciones después de eliminar outliers: 8932

Outliers eliminados: 777

```

In [81]: ## Guardar el DataFrame Limpio en un nuevo archivo CSV
raiz_proyecto = Path.cwd().parent
ruta_archivo = raiz_proyecto / "data" / "processed" / "credit_dataset_clean.csv"
df_clean.to_csv(ruta_archivo, index=False)

```

```


In [82]: sns.set_theme(style="whitegrid")

fig, axes = plt.subplots(nrows=1, ncols=3, figsize=(25, 12))

sns.boxplot(data=df_clean, x='Total_income', color='skyblue', ax=axes[0])
sns.boxplot(data=df_clean, x='Years_employed', color='salmon', ax=axes[1])
sns.boxplot(data=df_clean, x='Age', color='lightgreen', ax=axes[2])

plt.tight_layout()
plt.show()

```



En los datos originales, el Ingreso Total y los Años de Empleo tenían valores extremos irreales que aplastaban las gráficas y sesgaban los datos hacia la izquierda. La Edad no tenía problemas. Esos valores atípicos arrastran el promedio hacia arriba y aumentan dispersión, haciendo que los datos parezcan mucho más variables de lo que son. La mediana, en cambio, resiste bien esta distorsión ya que es una mediade dposición y no se ve afectada por valores extremos. Al aplicar el filtro usando el rango intercuartílico (IQR), las cajas recuperaron su tamaño y aunque seguimos observando outliers, estos ya no son tan extremos como antes.

11. Asociación lineal entre variables:


Seleccione al menos tres pares de variables cuantitativas y:

- Construya diagramas de dispersión:

```
In [83]: sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(1, 3, figsize=(22, 7))
fig.suptitle("Diagramas de Dispersión", fontsize=16, fontweight='bold')

sns.scatterplot(data=df_clean, x='Years_employed', y='Total_income', alpha=0.1, linewidth=0.4)
sns.scatterplot(data=df_clean, x='Age', y='Total_income', alpha=0.1, linewidth=0.4)
sns.scatterplot(data=df_clean, x='Age', y='Years_employed', alpha=0.1, linewidth=0.4)

plt.tight_layout()
plt.show()
```



- Calcule covarianza:

```
In [84]: pairs = [('Years_employed', 'Total_income'),
                  ('Age', 'Total_income'),
                  ('Age', 'Years_employed')]

for x, y in pairs:
    cov = np.cov(df_clean[x], df_clean[y])[0][1]
    print(f"Covarianza entre {x} y {y}: {cov}")
```

Covarianza entre Years_employed y Total_income: 43213.17907814599
 Covarianza entre Age y Total_income: -98023.83110353565
 Covarianza entre Age y Years_employed: -8.814914254640327

- Calcule Correlación de Pearson:

```
In [86]: pairs = [('Years_employed', 'Total_income'),
                  ('Age', 'Total_income'),
                  ('Age', 'Years_employed'),
                  ('Age', 'Unemployed'),
                  ('Num_children', 'Num_family')]

for x, y in pairs:
    corr = df_clean[x].corr(df_clean[y])
    print(f"Correlación de Pearson entre {x} y {y}: {corr}")
```

Correlación de Pearson entre Years_employed y Total_income: 0.13184255720175878
 Correlación de Pearson entre Age y Total_income: -0.11483360879152368
 Correlación de Pearson entre Age y Years_employed: -0.1647467565576354
 Correlación de Pearson entre Age y Unemployed: 0.6494358008071913
 Correlación de Pearson entre Num_children y Num_family: 0.8911434835239369

Al analizar el conjunto de datos limpio, se evidencia que la intensidad de la relación entre todas las variables es estadísticamente débil. En cuanto a la dirección de la relación, los años de empleo y el ingreso total muestran una tendencia positiva, indicando que a mayor experiencia suele corresponder un sueldo ligeramente mayor. Hay una correlación un poco más fuerte si hablamos de la edad y el estado de desempleo, lo que puede indicar que a más edad, mayor es la probabilidad de estar desempleado. Por el contrario, la edad presenta una

relación negativa tanto con el ingreso como con los años trabajados. A pesar de la baja correlación hay dos patrones observados fundamentales (Sobretudo en las gráficas): la presencia de franjas horizontales lo que puede sugerir salarios dados bandas tarifarias. Al comparar la edad y la experiencia se observa un triángulo vacío hacia la derecha, el cual confirma la restricción lógica de que los años trabajados nunca pueden superar la edad de la persona.

Informe Final de Análisis Exploratorio de Datos - *Credit Dataset*

1. ¿Cuáles son las variables más relevantes del conjunto de datos?

- **Económicas y Laborales:** `Total_income` y `Years_employed` son variables importantes para entender la situación financiera y laboral de los clientes.
- **Demográficas:** `Age`, `Num_children` y `Num_family` pueden ser útiles para segmentar a los clientes y entender su contexto familiar.
- **Categorías de Interés:** `Income_type`, `Education_type` y `Family_status` son clave para entender el tipo de ingresos, nivel educativo y estado civil, lo que puede influir en el comportamiento crediticio y también puede ser útil para segmentar a los clientes.
- **Variable Objetivo:** `Target`, que representa la variable a predecir, el 1180 que corresponde a un 13.2% de la muestra son un target positivo.

Tras la limpieza, la muestra se redujo de 9,709 a **8,932 registros** (se eliminó aproximadamente el 8% de los datos en outliers).

2. ¿Qué patrones y comportamientos importantes encontró en las distribuciones de los datos?

- **Desempleo y la Edad:** Existe un patrón donde la variable `Age` tiene una fuerte relación con la bandera de `Unemployed`. Esto sugiere que las personas de mayor edad en este conjunto de datos están clasificadas como "desempleadas", sin embargo, habría que confirmar estos datos ya que estas personas también pueden corresponder a **jubilados o pensionados**.
- **Concentración salarial:** El 75% de las personas gana 225,000 o menos (percentil 75), sin embargo, el promedio se ve arrastrado hacia arriba (181,228) debido a sueldos muy elevados en la cola derecha. Al eliminar estos outliers vemos que el ingreso máximo

cayó de 1.5 millones a **391,500**. Ahora el ingreso promedio real es de 169,471, una cifra mucho más representativa.

El proceso de limpieza modificó las variables numéricas principales:

- **Recuperación de la Normalidad (Ingreso y Empleo):**
 - La asimetría de `Total_income` bajó de 2.65 a **0.75**, y su curtosis de 15.78 a **0.13**.
 - Para `Years_employed`, la asimetría bajó a 1.03 y la curtosis a **0.35**.

3. ¿Qué variables presentan mayor dispersión, asimetría, curtosis o valores atípicos?

- **Asimetría Positiva (Sesgo a la derecha):** Las variables `Num_children` (3.61), `Total_income` (2.65) y `Years_employed` (1.84) están fuertemente sesgadas. La mayoría de los clientes tienen valores bajos, pero hay extremos muy largos hacia la derecha.
- **Curtosis:** `Num_children` tiene una curtosis de **48.02**, y `Num_family` de **18.30**. `Total_income` también presenta una curtosis muy alta de **15.78**. Esto matemáticamente confirma la presencia de outliers muy grandes.
- **Valores Atípicos Claros:** En el dataset existe un registro con **19 hijos**, un ingreso máximo de **1,575,000** muy alto respecto a la mediana (\$157,500) y personas con hasta **43 años de experiencia**.
- **Estabilidad:** La variable `Age` (Edad) es la más normal y estable, con asimetría de 0.15 y curtosis de -1.05.

4. ¿Qué pares de variables presentan asociaciones lineales fuertes?**

- **`Num_children` y `Num_family` (Pearson = 0.891):** Es la asociación lineal más fuerte de todo el conjunto. Es una correlación lógica, ya que el tamaño de la familia se calcula sumando a los hijos.
- **`Age` y `Unemployed` (Pearson = 0.649):** Una asociación positiva fuerte, confirmando el patrón mencionado de desempleo o jubilación/edad avanzada.
- **`Age` y `Years_employed` (Pearson = -0.164):** A mayor edad, los años de empleo continuo en esta muestra tienden a ser menores, influenciado por el bloque de adultos que pasan al estatus de "Pensionados".
- **`Years_employed` y `Total_income` (Pearson = 0.131):** Muestra que la experiencia aporta un impulso positivo pero no muy fuerte a los ingresos.

5. ¿Qué problemas de calidad de datos identificó en el conjunto de datos?

- **Outliers** La presencia de datos como los salarios de 1.5 millones rompe los cálculos de correlación de Pearson para el resto de la población normal, requiriendo aplicar los filtros (como el IQR) antes de poder trabajar con el dataset.
- **Aspectos positivos:** El dataset estructuralmente es muy limpio, no hay valores nulos (missing values = 0 en todas las 20 columnas) y no tiene filas duplicadas (0 duplicados).