

ENTREGABLE 1

FUNDAMENTACIÓN EN ANALÍTICA ESTRATÉGICA DE DATOS

Nombre del curso: Fundamentación en Analítica Estratégica de Datos

Título del proyecto: Etapa de preprocesamiento y análisis básico de un modelo estrella

Grupo:

Dataset asignado: dim_tienda.csv, dim_producto.csv, fact_ventas.csv

1. Instrucciones

1. El entregable debe evidenciar el desarrollo de un proceso de preprocesamiento aplicado a un **modelo estrella**.
2. Describir de manera clara las etapas de carga, exploración, limpieza, transformación, validación e integración de los datos.
3. Debe entregarse en Google Colab.
4. Para la socialización, el grupo deberá presentar un resumen ejecutivo con los principales resultados obtenidos (***análisis de resultados, paso 13 y análisis de hallazgos de Preprocesamiento, paso 15***) (presentación pptx).

2. Objetivo del proyecto

Desarrollar un proceso de preparación de datos sobre un modelo estrella compuesto por una tabla de hechos y dos tablas de dimensión, con el propósito de identificar problemas de calidad, aplicar transformaciones básicas, validar la integridad referencial e integrar la información para generar análisis descriptivos iniciales.

2.1 Objetivos específicos

- Comprender la estructura general de un modelo estrella.
- Cargar y explorar las tablas que conforman el modelo.
- Aplicar procesos de limpieza y transformación de datos.
- Validar la relación entre la tabla de hechos y las dimensiones.
- Crear columnas calculadas útiles para el análisis.
- Integrar los datos en una estructura consolidada para apoyar consultas y análisis básicos.

3. Contexto conceptual

Para este entregable se trabajará con una estructura compuesta por:

- una tabla de hechos: **fact_ventas**
- dos tablas de dimensión: **dim_tienda** y **dim_producto**

La tabla de hechos registra las transacciones de venta, mientras que las dimensiones aportan información contextual sobre las tiendas y los productos. Este modelo permite realizar análisis por diferentes criterios, como tienda, ciudad, producto, categoría o periodo de tiempo.

4. Descripción de las tablas

4.1 Tabla de hechos: fact_ventas

La tabla fact_ventas contiene la información transaccional asociada a las ventas registradas.

4.2 Tabla de dimensión: dim_tienda

La tabla dim_tienda contiene información descriptiva de las tiendas incluidas en el modelo.

Variables principales:

- id_tienda: identificador único de la tienda
- nombre_tienda: nombre de la tienda
- País: donde se encuentra ubicada

4.3 Tabla de dimensión: dim_producto

La tabla dim_producto contiene información descriptiva de los productos.

Variables principales:

- id_producto: identificador único del producto
- nombre_producto: nombre del producto
- categoria: categoría a la que pertenece
- costo base

5. Carga de los datos

La primera fase del proceso consiste en cargar los archivos que conforman el modelo estrella:

- dim_tienda.csv
- dim_producto.csv
- fact_ventas.csv

6. Exploración inicial de los datos

La exploración inicial tiene como finalidad conocer el estado original de la información antes de aplicar cualquier tarea de preprocesamiento.

Para ello se deben emplear instrucciones como:

- `head()`, para visualizar los primeros registros
- `info()`, para revisar la estructura y los tipos de datos
- revisión general de nombres de columnas y contenido

Además, se debe identificar:

- Estructura general de cada tabla
- Tipo de datos de cada columna
- Inconsistencias en columnas y valores
- Presencia de valores nulos
- Existencia de registros duplicados
- Columnas relevantes para el análisis

7. Limpieza de datos

Con base en los hallazgos de la exploración inicial, se aplican procesos de limpieza orientados a mejorar la calidad de los datos.

Actividades desarrolladas

- Eliminación de registros duplicados
- Depuración de espacios en blanco innecesarios en variables de texto
- revisión de consistencia en los valores categóricos
- Verificación de registros duplicados
-

8. Manejo de valores nulos

Acciones realizadas

- Identificación de valores nulos en cada tabla.
- completar valores en variables donde no se disponga información

9. Conversión de tipos de datos

- Hacer la conversión en aquellas columnas que lo requieran de acuerdo con los cálculos o medidas que deban realizarse.

10. Validación de integridad referencial

Comprobar que los identificadores presentes en la tabla de hechos tengan correspondencia en las tablas de dimensión.

Validaciones realizadas

- identificación de ventas cuyo id_tienda no aparece en dim_tienda
- identificación de ventas cuyo id_producto no aparece en dim_producto

11. Creación de columnas calculadas

Generar nuevas variables que enriquecen la capacidad analítica del conjunto de datos.

Ejemplo de nuevas columnas

- total_venta, calculada como: cantidad * precio
- año, extraído a partir de la variable fecha
- mes, extraído a partir de la variable fecha

12. Integración del modelo estrella

Una vez completadas las etapas de limpieza, transformación y validación, se procede a integrar las tablas del modelo.

Proceso de integración

1. unión de fact_ventas con dim_producto
2. unión del resultado con dim_tienda

Como producto de esta integración se obtiene una tabla consolidada, en la cual cada registro de venta queda enriquecido con información descriptiva sobre el producto y la tienda correspondiente.

Esta tabla integrada constituye la base para realizar análisis descriptivos más completos.

13. Análisis de resultados

A partir de la tabla consolidada (**paso 12**), desarrollar las siguientes consultas como análisis iniciales que permiten interpretar el comportamiento de las ventas y validar la calidad de la información procesada.

1. Identificar la categoría que genera mayores ingresos.
2. Calcular la cantidad total de unidades vendidas por producto.
3. Calcular el ingreso total generado por cada producto.
4. Determinar el promedio de ventas por tienda.
5. Analizar el total de ventas por país.
6. Identificar el país con mayores ingresos.

7. Calcular el total de ingresos por trimestre.
8. Identificar el mes con mayor volumen de ventas.
9. Comparar el desempeño de las tiendas por categoría de producto.
10. Identificar los 5 productos con mayores ingresos.
11. Identificar las 5 tiendas con mayor cantidad de unidades vendidas.
12. Analizar la evolución mensual de ventas por categoría.
13. Determinar qué producto tiene mayor ingreso dentro de cada categoría.
14. Identificar tiendas con bajo desempeño en ventas.
15. Calcular el promedio de precio por categoría.

14. Archivo de salida

Como resultado final de la etapa de preprocesamiento, se debe generar un archivo consolidado denominado:

`ventas_limpias.csv`

Este archivo debe contener los datos depurados, transformados e integrados, listo para ser utilizado en procesos posteriores de visualización, modelado o análisis más avanzados.

15. Análisis de Hallazgos de Preprocesamiento.

Con base en el proceso realizado, cada grupo debe presentar una interpretación preliminar de los hallazgos obtenidos. Esta interpretación puede centrarse en aspectos como:

- problemas de calidad identificados en las tablas originales
- consistencia entre la tabla de hechos y las dimensiones
- comportamiento general de las ventas
- tiendas con mayor participación
- categorías que generan mayores ingresos
- patrones temporales básicos observados en la información

Este análisis debe enfocarse en describir lo encontrado y en explicar la importancia de las transformaciones realizadas.